

Klasifikacija nad skupom podataka *Mental Health Symptoms & Illness*

Student: Viktor Šević 91/2022

Profesor: Mirjana Maljković Ružičić

[Link](#) ka izvoru skupa podataka

1 Opis zadatka

Cilj rada je klasifikacija psihičkih poremećaja i oboljenja primenom metoda mašinskog učenja na osnovu prisutnosti ili odsustva kliničkih simptoma kod pacijenata. Skup podataka inspirisan kriterijumima iz DSM-5 (Dijagnostički i statistički priručnik za mentalne poremećaje) i sintetički je generisan i unapređen u edukativne svrhe.

2 Opis podataka

Skup podataka u CSV formatu sadrži ukupno 8304 instanci koje predstavljaju pacijente/dijagnoze i 186 atributa koji predstavljaju simptome. Atributi su predstavljeni kao binarni indikatori prisustva simptoma, gde vrednost 0 označava odsustvo, a 1 prisustvo simptoma. Kategorička promenljiva "Disease" predstavlja konačnu dijagnozu. Obuhvata 23 klase od kojih se 22 odnose na bolesti, a vrednost "No illness" predstavlja osobu kojoj nije ustanovljen poremećaj.

3 Predprocesiranje podataka

Proverom je utvrđeno da skup podataka ne sadrži nedostajuće vrednosti i da su sve vrednosti atributa binarnog karaktera pa nema ni ekstremnih vrednosti. Kategorije su približno ravnomerno raspoređene.


Ciljna promenljiva "Disease" kodirana je koristeći *LabelEncoder*.

Formiramo tri skupa atributa od kojih prvi sadrži sve attribute, drugi najboljih 15 i treći sadrži 10 atributa dobijenih pomoću PCA (*Principal Component Analysis*).

4 Reprezentacija podataka u 3D

Pomoću PCA svodimo podatke na 3 komponente pomoću kojih ih prikazujemo u prostoru i primećujemo da se klasteruju u grupe. (Slika 1)

3D PCA Prikaz Podataka




Slika 1

5 Konstruisanje modela

Konstruišemo 6 modela koji će nam služiti za klasifikaciju:

- **Random Forest:** Ansambl stabala odlučivanja pogodan za nelinearne odnose i binarne matrice. Radi tako što kreira mnoštvo nezavisnih stabala na slučajnim podskupovima podataka i atributa, pa konačnu odluku donosi većinskim glasanjem.
- **SVM (Support Vector Machine):** Algoritam pronalazi optimalnu hiperravan koja maksimizuje marginu između različitih klasa, pri čemu pomoću kernel funkcija može efikasno rešavati i nelinearno razdvojive probleme. Zelimo nelinearni kernel jer nemamo jasnu granicu između kategorija.
- **Decision Tree:** Osnovni model zasnovan na pravilima grananja.
- **KNN (K-Nearest Neighbors):** Algoritam zasnovan na rastojanju između primera. Nova instanca se klasifikuje proverom k najbližih suseda u prostoru atributa i dodeljivanjem klase koja je najzastupljenija među njima.
- **Logistic Regression:** Meri odnos između ulaznih atributa i verovatnoće pripadnosti dijagnozi.
- **Bernoulli Naive Bayes:** Probabilistički model posebno prilagođen za binarne podatke. Zasniva se na primeni Bajesove teoreme uz pretpostavku da je prisustvo svakog simptoma nezavisno od ostalih u okviru date klase.

6 Analiza rezultata



Slika 2

Skup Atributa	Algoritam	Accuracy	F1-Score
Svi Atributi	KNN	0.9755	0.9760
Svi Atributi	Logistic Regression	0.9747	0.9747
Svi Atributi	BernoulliNB	0.9727	0.9719
Svi Atributi	SVM	0.9727	0.9727
Svi Atributi	Random Forest	0.9723	0.9716
Svi Atributi	Decision Tree	0.8379	0.8401
PCA (10 Komponenti)	KNN	0.9671	0.9671
PCA (10 Komponenti)	Random Forest	0.9663	0.9663
PCA (10 Komponenti)	Logistic Regression	0.9651	0.9651
PCA (10 Komponenti)	SVM	0.9643	0.9644
PCA (10 Komponenti)	Decision Tree	0.9197	0.9198
PCA (10 Komponenti)	BernoulliNB	0.8162	0.8065
SelectKBest (Top 15)	BernoulliNB	0.3929	0.3709
SelectKBest (Top 15)	Logistic Regression	0.3929	0.3711
SelectKBest (Top 15)	SVM	0.3917	0.3696
SelectKBest (Top 15)	Random Forest	0.3913	0.3700
SelectKBest (Top 15)	Decision Tree	0.3904	0.3691
SelectKBest (Top 15)	KNN	0.3872	0.3680

Za ocenu modela su korišćene sledeće metrike:

- **Tačnost (Accuracy):** Predstavlja odnos broja tačno klasifikovanih pacijenata i ukupnog broja uzoraka u testnom skupu, dajući osnovni uvid u opštu preciznost algoritma.
- **F1-Score:** Predstavlja harmonijsku sredinu preciznosti (procenat tačnih pozitivnih dijagnoza) i odziva (sposobnost modela da detektuje sve stvarne slučajeve bolesti), čime se osigurava stabilna ocena performansi i sprečava da jedna dominantna klasa prividno podigne ocenu modela.


7 Zaključak

Na osnovu rezultata možemo da zaključimo da 15 najznačajnijih atributa nije dovoljno za uspešnu klasifikaciju nad ovim skupom podataka. Mogući uzrok tako slabog rezultata može biti činjenica da se veliki broj simptoma bolesti preklapa.

Projektovanje 185 binarnih simptoma u samo 10 neprekidnih PCA komponenti zadržava izuzetno visok nivo informacija. *Decision Tree* i *Bernoulli Naïve Bayes* imaju najveća odstupanja u odnosi na ovaj skup atributa što je i očekivano. Stablo odlučivanja ima značajno bolje rezultate na PCA redukovanom skupu jer mu PCA komponente olakšavaju donošenje odluka u odnosu na retku binarnu matricu. S druge strane, *BernoulliNB* beleži pad u tačnosti jer PCA komponente nisu binarne varijable već neprekidni brojevi, čime se narušava njegova osnovna pretpostavka.

8 Dodatna zapažanja

Radi dodatne analize možemo da prikažemo značajnost parametara za klasifikaciju date bolesti. Primer graničnog poremećaja ličnosti (Borderline personality disorder) (Slika 3)



Zanimljivo je da se atribut *"persisitent_worry_about_losing_attachment_figures"* ne nalazi ni blizu skupa najznačajnijih atributa iako bi po DSM-5 on trebalo da je jedan od glavnih simptoma ovog poremećaja. Analizom skupa podataka uočavamo da se taj simptom ne pojavljuje u 98.45% uzoraka. Kako je skup podataka sintetički generisan ovo je mogući znak greške.